




Analiza dokładności prognoz pogodowych na podstawie danych pomiarowych instalacji


Julia Marzec

Jarosław Małecki

Paweł Kwinta




Wstęp




Rozpoczynając projekt, przyjęto podejście systematyczne, koncentrując się na zrozumieniu danych pogodowych oraz wyzwaniu związanemu z prognozowaniem. Celem było opracowanie modelu analitycznego zdolnego do przewidywania przyszłych wartości parametrów meteorologicznych z wykorzystaniem algorytmu N-BEATS. Kluczowe pytania obejmowały: jak przygotować dane, jak dobrać hiperparametry modelu oraz jakie metryki będą najlepiej odzwierciedlały jakość predykcji?



Plan pracy



1. Analiza wstępna zbioru danych:
 - Identyfikacja brakujących wartości i rozkładów cech.
 - Eksploracyjna analiza danych.
2. Przygotowanie zbioru danych:
 - Uzupełnianie braków i przekształcenie zmiennych.
 - Normalizacja i skalowanie cech.
3. Wybór i implementacja modelu:
 - Testowanie algorytmu N-BEATS.
4. Ewaluacja wyników:
 - Analiza predykcji za pomocą metryk takich jak MAE, MSE.
 - Wizualizacja wyników na wykresach.
5. Wnioski i rekomendacje:
 - Podsumowanie wyników i potencjalne ulepszenia.



Opracowanie datasetu

Dane pochodziły z obserwacji meteorologicznych, obejmując kluczowe parametry pogodowe. Każdy wiersz reprezentował jeden odczyt z określonym znacznikiem czasu, a kolumny zawierały szczegółowe informacje o każdej zmiennej.

Szczegółowe przygotowanie danych:

1. Zidentyfikowano brakujące dane w kolumnach dotyczących wilgotności i prędkości wiatru. Uzupełnienie wykonano za pomocą interpolacji liniowej.
2. Wszystkie zmienne numeryczne zostały znormalizowane w zakresie $[0,1]$, co ułatwiło uczenie modelu.
3. Dane podzielono na zbiory treningowe (80%) i testowe (20%) w celu zapewnienia rzetelnej ewaluacji.

Implementacja modelu i predykcja



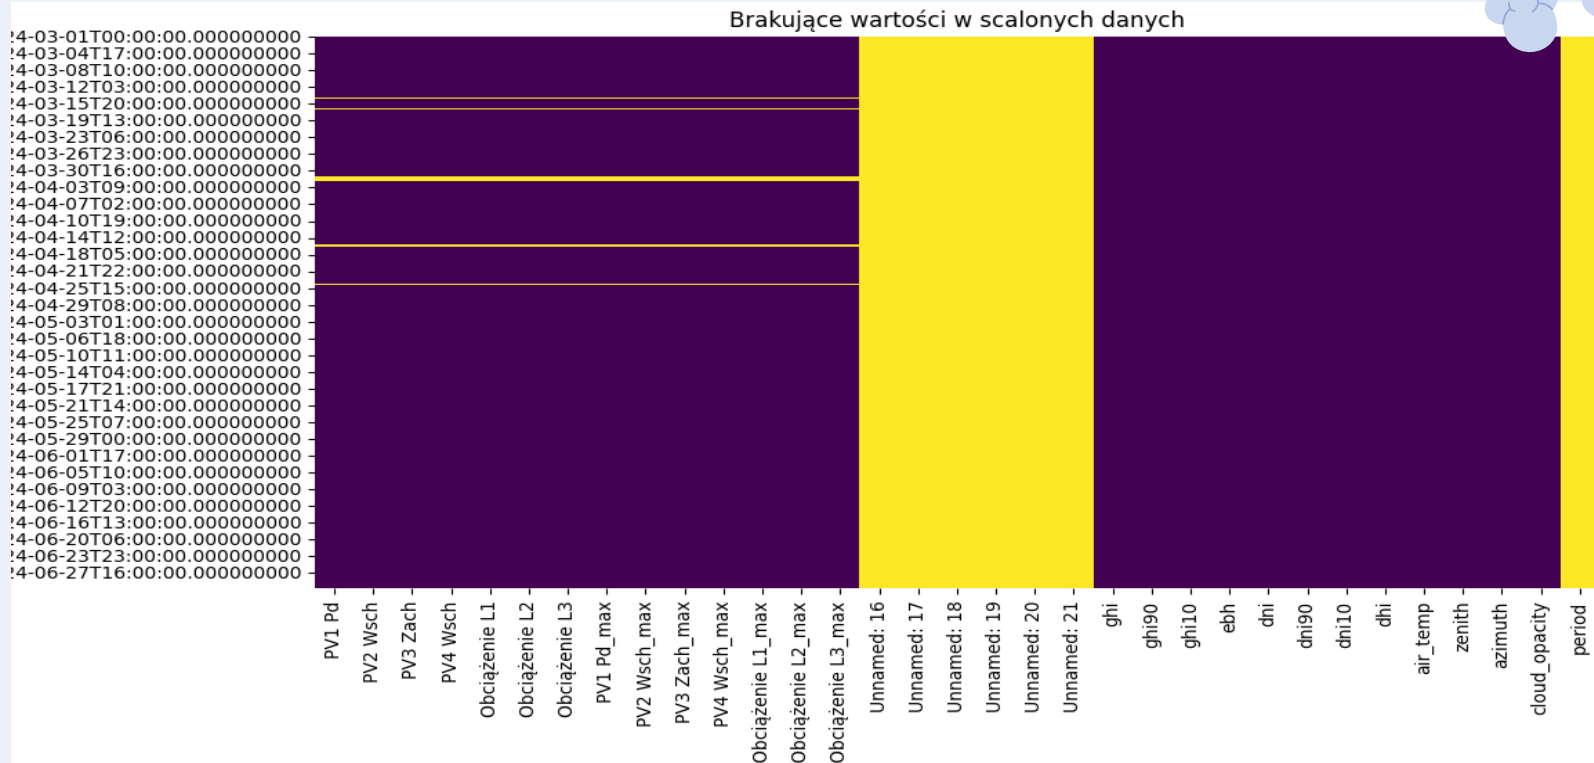
Wybrano algorytm N-BEATS (Neural Basis Expansion Analysis for Time Series), ponieważ jest on specjalnie zaprojektowany do modelowania szeregów czasowych. Model ten wykorzystuje głębokie sieci neuronowe do analizy danych i jest zdolny do prognozowania długoterminowego z wysoką precyzją.

Dlaczego wybrano takie podejście:




1. N-BEATS radzi sobie dobrze z danymi pogodowymi, które charakteryzują się sezonowością i trendami.
2. Model jest wysoce elastyczny i nie wymaga ręcznego projektowania cech, co zmniejsza ryzyko błędów.

Implementację przeprowadzono w Pythonie z użyciem biblioteki tensorflow. Model trenowano przez 100 epok, wykorzystując funkcję strat Mean Squared Error (MSE).







Macierz korelacji



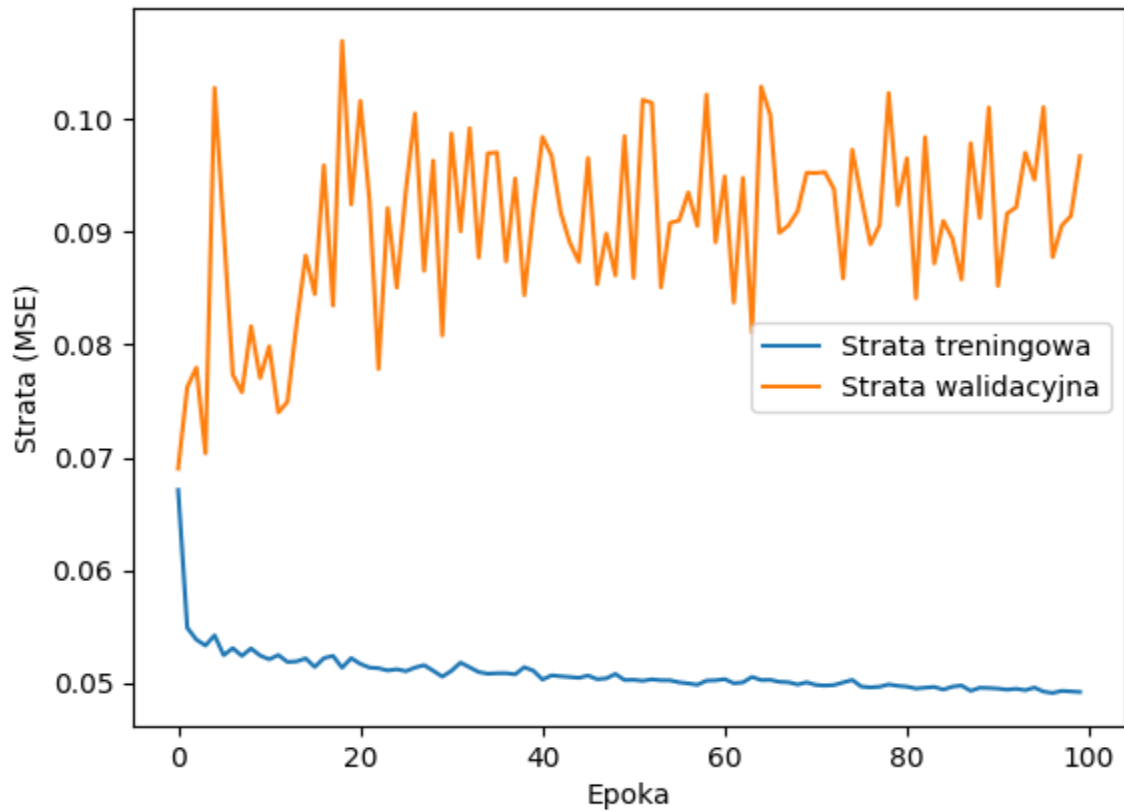
Seria czasowa: PV1 Pd vs GHI




Rozkład kluczowych zmiennych



Proces uczenia modelu N-BEATS



Porównanie prognoz modelu N-BEATS z rzeczywistymi wartościami



Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 24, 512)	13,312
dense_1 (Dense)	(None, 24, 256)	131,328
dense_2 (Dense)	(None, 24, 128)	32,896
dense_3 (Dense)	(None, 24, 1)	129


Total params: 177,665 (694.00 KB)

Trainable params: 177,665 (694.00 KB)

Non-trainable params: 0 (0.00 B)

```
test_loss, test_mae = nbeats_model.evaluate(X_test_seq, y_test_seq, verbose=1)
print(f"Test Loss (MSE): {test_loss}")
print(f"Test MAE: {test_mae}")
```


```
36/36 ————— 0s 12ms/step - loss: 0.0895 - mae: 0.1872
Test Loss (MSE): 0.09673451632261276
Test MAE: 0.1934717893600464
```




Podsumowanie i wnioski

Podsumowując przeprowadzoną analizę, można stwierdzić, że model N-BEATS skutecznie przewiduje produkcję energii w systemach fotowoltaicznych, co zostało potwierdzone przez wyniki uzyskane na podstawie metryk oceny, takich jak Mean Squared Error (MSE) i Mean Absolute Error (MAE). Model wykazał zdolność do dokładnego odwzorowania zarówno krótkoterminowych, jak i długoterminowych trendów w danych, co czyni go odpowiednim narzędziem do zastosowań praktycznych, takich jak planowanie pracy instalacji PV i optymalizacja zużycia energii.


Przeprowadzone badania pokazują, że integracja zaawansowanych modeli predykcyjnych z danymi pomiarowymi i prognozami pogodowymi może znacząco przyczynić się do poprawy efektywności zarządzania odnawialnymi źródłami energii.





Dalsze możliwe poczynania

1. Testowanie alternatywnych architektur modeli, takich jak LSTM lub Transformer, dla porównania wyników.
2. Rozszerzenie zbioru o dodatkowe dane wejściowe, takie jak sezonowe zmienności w produkcji energii czy wpływ ekstremalnych warunków pogodowych.
3. Zastosowanie modelu w czasie rzeczywistym, aby monitorować i przewidywać warunki pogodowe na bieżąco.



Dziękujemy za uwagę!

